

# 研究倫理を考慮した Human-in-the-Loop 型 LLM 対話支援による HUMINT の実証実験

久保 颯汰<sup>†</sup> 長山 侑央<sup>†</sup> インミンパパ<sup>††</sup> 吉岡 克成<sup>†††,††</sup>

<sup>†</sup> 横浜国立大学大学院環境情報学府

<sup>††</sup> 横浜国立大学先端科学高等研究院

<sup>†††</sup> 横浜国立大学環境情報研究院

E-mail: <sup>†</sup>{kubo-sota-dj,nagayama-yukihiro-py}@ynu.jp, <sup>††</sup>{yinminn-papa-jp,yoshioka}@ynu.ac.jp

**あらまし** Telegram 等の SNS を用いた人的情報収集 (HUMINT) は, OSINT では得られない深層的な脅威インテリジェンスの獲得に極めて有効であるが, コミュニティ特有の隠語の理解や言語の差異, 研究倫理の遵守といった障壁が存在し, 適切に実施するには専門的知識と経験を要する. 本研究では, 大規模言語モデル (LLM) を対話支援ツールとして活用し, 研究倫理に配慮しながら調査者の負担を抑えて HUMINT を遂行するための手法を提案する. 提案手法では, 実際の攻撃者との対話前に LLM が攻撃者の投稿内容を解析し, 文脈に即した発言候補を対話ツリーとして生成する. さらに, 対話ツリーを含む対話ルールをもとに擬似攻撃者 LLM とのロールプレイを行い, 十分な準備を行なった上で実験を行う. 実証実験として, Telegram 上でスパムツールの販売を宣伝する攻撃者 10 名を対象に, 決済手段の特定を試みた. その結果, 10 名全員と対話が成立し, うち 7 名から暗号資産の送金先アドレスを取得した. あわせて, 商品・価格体系や踏み台として悪用される正規サービス, さらに暗号資産による直接送金や入金確認の方法, 初期設定の代行といった取引運用の実態についても知見を得た. これらの対話において, 倫理的に問題のある発言は確認されなかった.

## An Empirical Study of Ethical HUMINT through Human-in-the-Loop LLM Dialogue Support

Sota KUBO<sup>†</sup>, Yukihiro NAGAYAMA<sup>†</sup>, Yin Minn Pa Pa<sup>††</sup>, and Katsunari YOSHIOKA<sup>†††,††</sup>

<sup>†</sup> Graduate School of Environment and Information Sciences, Yokohama National University

<sup>††</sup> Institute of Advanced Sciences, Yokohama National University

<sup>†††</sup> Faculty of Environment and Information Sciences, Yokohama National University

E-mail: <sup>†</sup>{kubo-sota-dj,nagayama-yukihiro-py}@ynu.jp, <sup>††</sup>{yinminn-papa-jp,yoshioka}@ynu.ac.jp

**Abstract** Human intelligence (HUMINT) using social networking services (SNS) such as Telegram is highly effective for acquiring deep threat intelligence that is unobtainable through open-source intelligence (OSINT). However, it requires specialized knowledge and experience to execute properly due to barriers such as language differences, community-specific jargon, and strict adherence to research ethics. In this study, we propose a method that utilizes Large Language Models (LLMs) as a dialogue assistance tool to conduct HUMINT while alleviating the investigator's burden and ensuring ethical compliance. In the proposed method, prior to interacting with actual attackers, an LLM analyzes the attackers' posts and generates context-aware utterance candidates in the form of a dialogue tree. Furthermore, role-playing sessions are conducted with a simulated attacker LLM based on dialogue rules that incorporate this dialogue tree, ensuring thorough preparation before the actual experiment. As a demonstration experiment, we attempted to identify the payment methods of 10 attackers advertising spam tools on Telegram. As a result, successful dialogues were established with all 10 attackers, and cryptocurrency transfer addresses were obtained from 7 of them. Additionally, we gained insights into the reality of their transaction operations, including product and pricing structures, legitimate services abused as stepping stones, direct cryptocurrency transfers, payment confirmation methods, and initial setup agency services. No ethically problematic statements were observed throughout these interactions.

## 1. はじめに

Telegram 等の匿名性に優れたソーシャルネットワーキングサービス (SNS) を用いた人的情報収集 (HUMINT) は、現代の脅威インテリジェンス構築において極めて有益な手法である。その最大の優位性は、公開情報を対象とする OSINT (Open Source Intelligence) では到達困難な、クローズドな通信に含まれる深層的情報を取得できる点にある。

しかし、有人による HUMINT の実施には言語的、文化的、そして倫理的な障壁が存在する。まず言語面では、攻撃者のコミュニティで多用される特有の隠語や略称、意図的な難読化を解読し、その文脈を正確に把握する必要がある。さらに、独自の文化や言語圏の差異を越えて自然なコミュニケーションを維持し、対話を構築するには、高度な言語能力と多大な時間を継続的に投入する必要がある。加えて、研究倫理の遵守も大きな課題である。メンロレポート等の指針に基づき、プライバシーや対象者への影響を考慮しながら HUMINT を行うことは容易ではない。先行研究 [1] では、LLM を用いた対話による情報収集の試みが見られるものの、各発言プロセスにおける具体的な倫理的判断基準や、調査者による介入を含めた管理体制については、十分に明文化されているとは言い難い。

本研究の目的は、これらの課題を克服し、LLM を活用して効率的かつ倫理的に HUMINT を遂行するための汎用的な手法を提案することにある。

近年の LLM の高度な文脈理解能力を対話支援ツールとして活用して調査者の負担を軽減し、コミュニティ特有の文脈に即した対話の流れを予想し、対話ツリーを生成する。このツリーを生成する対話ツリー生成 LLM にはメンロレポートに基づく倫理的制約をプロンプトとして与えており、安全な対話の実現を図る。ただし LLM はツールとしての利用にとどめ、意思決定の主体は人間に置く。調査者は対話ツリー内の発言候補のうち「研究倫理上の妥当性」「購入者としての自然さ」「情報の有用性」の3つの観点から適切なものを選んで送信し、適切な候補がなければ対話を中止する。特に、「研究倫理上の妥当性」に関しては、調査者がメンロレポート [2] の内容をもとに、発言のリスクと恩恵を比較することで妥当性を判断した。

本研究では、提案手法の有用性を実証するため、2026 年 5 月 14 日から 2026 年 5 月 24 日にわたり、Telegram の公開グループ上でスパムツールやなりすまし電話ツール等の販売を宣伝する攻撃者およびその連絡先を対象とした実証実験を実施した。合計 10 名に接触を試みたところ、10 名すべてと対話が成立し、総計 174 発話に及ぶ対話を行った。提案手法により、OSINT では取得しにくい情報を獲得できた。具体的には、7 件の暗号資産送金先アドレスに加え、商品カテゴリと価格体系、踏み台として悪用される正規サービス、標的とされる国・地域に関する知見である。さらに、犯罪エコシステムの実態を示す質的な知見も得られた。決済は暗号資産の直接送金に限られ、仲介業者は介在しなかった。販売者は入金をスクリーンショットやトランザクションハッシュで確認し、利用開始までの所要時間の提示や初期設定の代行といった顧客対応も

行っていた。また、複数の販売者間で共通する定型的な営業文句も観察された。これらの対話を通じて、倫理的に問題のある発言は確認されなかった。

本論文の主要な貢献は以下の 3 点である。

1. **人間中心型 (Human-in-the-loop) の対話支援手法の提案**：LLM を用いて攻撃者の投稿内容を解析し、文脈に即した複数の対話候補 (質問群および予測返答群) をあらかじめ生成する手法を構築した。従来、コミュニティ特有の隠語の解読や自然な対話の構築には高度な専門知識と多大な時間を要したが、本手法はこうした作業を LLM に事前に担わせることで、HUMINT の実施に必要な専門知識の障壁を下げる。
2. **発言ごとの倫理的検証の実施**：生成された対話候補に対し、調査者が 3 基準に基づいて最適な発言を選択・修正する運用フローを確立した。特に、特定のターゲット指定を求められる等のリスクを調査者が能動的に検知し、対話を中断・制御する判断基準を明文化した。
3. **実証的なインテリジェンス獲得の成功**：Telegram 上の不正ツール販売コミュニティを題材とし、OSINT では到達困難であった決済情報の収集を通じて手法の有効性を検証した。さらに、対話ログの分析を通じて、攻撃者の活動パターンに関する新たな知見を提示した。

本稿では、第 2. 章で関連研究を整理し、第 3. 章で提案手法を、第 4. 章で実際の攻撃者に向けた対話準備、第 5. 章で実際の攻撃者との対話結果を述べる。続いて第 6. 章で考察、第 7. 章で倫理的考慮、第 8. 章で今後の展望を述べる。

## 2. 関連研究

### 2.1 HUMINT と脅威インテリジェンス

SNS 等を対象とした HUMINT は深層的な脅威インテリジェンス獲得に有効だが、潜入調査特有の倫理的課題や接触・信頼構築の困難さが指摘されている [3]~[5]。これらの研究は HUMINT の有用性と困難を示す一方、調査の各段階における倫理的判断や、調査者の負担を軽減する具体的な支援手法には踏み込んでいない。

### 2.2 LLM を活用した HUMINT

鈴木ら [1] は、LLM を用いた HUMINT 支援フレームワークを提案し、「擬似攻撃者 LLM」との対話で調査者の知識不足や言語的障壁を補い、対話の倫理性を監視する仕組みを示したが、検証はロールプレイにとどまった。Siadati ら [6] は LLM による自動スキャンベディングを実在の詐欺師 2,600 名以上に適用し、送金先口座などの金銭情報を引き出せることを示したが、対話は完全自動であり、発言ごとの倫理的判断を人間が担う設計ではない。また長山ら [7] は、メンロレポートに基づく倫理チェックリストを設計し、LLM による発言の倫理性判定の信頼性を評価したが、検証はシミュレーション対話にとどまる。本研究は、実在する攻撃者との対話に、発言の選択・修正・中止からなる人間中心の倫理的制御フローを適用し




図 1: Human-in-the-loop 型 HUMINT 支援システムの全体構成

て実証する点でこれらと異なる。

### 2.3 研究倫理とインフォームド・コンセント、秘匿調査

人間を対象とする情報通信技術研究の倫理指針であるメンロレポート [2] は、便益とリスクの均衡・人格の尊重・正義・法と公益の尊重を原則とし、インフォームド・コンセントの取得を求める。しかし攻撃者を対象とする HUMINT では、研究目的の開示が対象の警戒を招き調査が成立しない恐れがある。実際、著者らの先行研究 [8] では同意取得を試みた結果、接触した 30 名のうち同意率は 0% であった。

### 2.4 OSINT によるサイバー犯罪市場の分析

Telegram 等を対象とした OSINT 研究は、サイバー犯罪エコシステムの把握に成果を上げている。青砥ら [9] は類似チャンネル提示機能で犯罪関連チャンネルを分析し、Morag [10] は地下市場のチャットを大規模に分析し、流通するフィッシングキット (Phishing-as-a-Service) の市場構造を明らかにしている。これらは公開情報の知見を広げる一方、送金先アドレスのような決済手段は個別対話でのみ開示される限界があり、本研究の HUMINT はこの層を補完的に獲得する手段となる。

## 3. 提案手法

本章では、大規模言語モデル (LLM) を活用し、倫理的に Telegram 等の匿名 SNS 上で人的情報収集を遂行するための、人間中心型対話支援手法について詳述する。

### 3.1 提案手法の全体構成

本研究が提案する手法は、大規模言語モデルの文脈理解・生成能力と、調査者 (人間) による倫理的な意思決定を統合した「人間中心型」の HUMINT 支援アーキテクチャである。実際の攻撃者との対話の前に対話ツリーの生成やロールプレイを通じた検証を行い、十分に準備した上で、実験を行なった。

図 1 は、提案手法の全体構成と、主要な構成要素間の相互作用を示したものである。図中の数字はステップ 1 からステップ 5 までの 5 段階で構成される手法の手順に対応する。各ステップの詳細は 3.2 以降で説明する。本手法は、対象者が発信した公開情報を起点とし、主に以下の 4 つのコンポーネントの協調によって構成される。

#### (1) 調査者 (Human Investigator):

LLM が提示した攻撃者の公開情報の分析結果と発言の提




図 2: LLM による対話候補の対話ツリーの動的生成

案を評価し、最終的な意思決定を行う主体である。後述の 3 基準 (3.4 節) に基づき適切な発言を選択・修正して調査対象者 (攻撃者) との対話を行い、倫理的レッドラインを超える要求があった場合は対話を中断する。調査者が自ら作成した発言素案を LLM に与え、攻撃者特有の口調に書き換えさせるなどの指示も担う。なお、本手法における調査者は最低限メンロレポートの内容を理解している人間である必要がある。

#### (2) 対話ツリー生成 LLM:

入力された攻撃者の公開情報を基に、投稿の分析と対話ツリーの生成を行う。本手法の中核を成すこのコンポーネントは、主に以下の機能と特徴を持つ。

**公開情報の分析と詳細解説:** 入力された攻撃者の公開情報をシステムが受け取り、その内容を分析する。単なる翻訳にとどまらず、投稿の 1 行ごとにその意味や、背後に含まれるサイバー犯罪特有の技術用語、隠語の詳細を平易に解説する機能を持つ。この機能は調査者が投稿内容から攻撃者の実態を理解する助けとなる。

**ペルソナの付与:** 対話ツリーの生成時に、攻撃者に怪しまれないための適切なペルソナが LLM にプロンプトとして与えられる。

**対話ツリーの生成:** 分析結果とペルソナ設定に基づき、単純な 1 ターンの返答ではなく、数手先を見越した「対話ツリー」を生成する。具体的には、図 2 のように、攻撃者の投稿内容 (POST) を起点として、会話のきっかけとなる複数の質問候補 (質問群 X) を生成する。次に、選択した質問に対して対象者から来ると予想される複数の返答パターン (予測返答群 A) を展開し、さらにそれぞれの予測返答に対応する次の一手となる質問候補 (質問群 Y) を生成するという木構造をとる。対話ツリーは対話相手との会話開始直後の発言に利用する。

**倫理的制約の遵守とリスクの明示:** 対話ツリーを生成するプロンプトには、違法なチュートリアルやマルウェア本体の要求、被害者データの受け取り、具体的な攻撃ターゲットの指定など、メンロレポート [2] の内容をもとに、倫理的観点から危険と思われる発言の生成を厳格に禁止するルールが組み込まれている。さらに、出力された対話ツリーの各発言候補には、それを送信した際に伴う潜在的な倫理的リスクや注意点が明記されており、調査者の判断を支援する。

### (3) 擬似攻撃者 LLM:

実際の攻撃者の発言を模した LLM. 調査者はこの LLM とのロールプレイを通じて、対話ツリーを基に行われる会話が実際の攻撃者にも適用可能か検証する. LLM には、ロールプレイを行う背景、攻撃者としての役割や性格、話し方、考え方等を設定する.

### (4) 対話ルール:

調査者が攻撃者と対話を行う際に参照するルール. 対話の内容をあらかじめ予測し、倫理的に問題のない解答を対話ルールとしてあらかじめ用意しておくことで、安全性を高めている. 対話ツリーや後述する固定質問群 Z、例外処理が含まれる.

本手法は、これらのコンポーネントが以下の手順（ステップ 1～5）で連携することにより進行する.

#### 3.2 ステップ 1: 収集目標の設定

ステップ 1 では、調査者が OSINT によって対象者の公開情報を分析し、HUMINT によって追加的に取得すべき収集目標を定める. ここでいう公開情報には、SNS やフォーラム上の宣伝投稿、販売対象として掲げられているサービス、価格や連絡先など、対象者が自ら公開している情報が含まれる.

#### 3.3 ステップ 2: 対話ルールの初期設定

ステップ 2 では、ステップ 1 で定めた収集目標を安全に達成するため、調査者が対話ルールを設定する. 対話ルールは、調査者が実対話中に参照する行動指針であり、固定質問群 Z、対話ツリー、例外処理、から構成される. これらを事前に定めることで、調査者が場当たりに応答することを避け、倫理的に許容できる範囲内で一貫した対話を進められるようにする.

固定質問群 Z は、収集目標を達成するために対話中で必ず確認する質問群である. 接触直後の自然な会話は対話ツリーに基づく発言候補に委ねる一方で、収集目標に直結する質問は固定質問群 Z として用意しておく. これにより、対話が相手の反応に左右されても、調査者は必要な情報に向けて段階的に会話を戻すことができる. ただし、固定質問群 Z に含める質問は、研究目的に必要であり、かつメンロレポート [2] に照らして過度な危害を生じさせないものに限定する.

さらに、固定質問群 Z や対話ツリーでは対応できない状況を想定し、例外処理を用意する. 例外処理は、倫理的リスクが高い場面での回避方針や中止方針を含める. これにより、調査者は実対話中に即興で危険な判断を行うのではなく、事前に検討した安全な方針に従って応答できる.

#### 3.4 ステップ 3: ロールプレイによる安全性の検証

ステップ 3 では、ステップ 2 で初期設定した対話ルールが実際の対話で機能するかを、擬似攻撃者 LLM とのロールプレイによって検証する. 調査者は、対象者の公開情報、設定したペルソナ、固定質問群 Z、対話ツリー、例外処理を用いて、実対話を模したやり取りを行う. 擬似攻撃者 LLM に、攻撃者の発言を模倣させることで、対話ルールの弱点を事前に洗い出す.

調査者は、対象となる攻撃者を一人選定し、公開情報を対話ツリー LLM に入力する、対話ツリー LLM の出力を確認し、

攻撃者の情報を理解する. 対話開始直後、対話ツリー内の質問群 X や質問群 Y、に対して、以下の三つの基準で評価を行う.

- (1) **研究倫理上の妥当性 (Ethical Validity):** メンロレポート等に準拠し、被害者データの要求、具体的な攻撃ターゲットの指定、犯罪行為の助長につながる発言が含まれていないかを確認する.
- (2) **購入者としての自然さ (Naturalness):** コミュニティの文脈、使用言語、隠語、設定したペルソナに照らして、相手に過度な警戒心を抱かせない自然な発言であるかを確認する.
- (3) **情報の有用性 (Information Usefulness):** その質問をすることで得られる情報の社会的有用性を確認する.

基本フローとして、調査者はこれら三つの基準を満たす候補の中から発言を選択する. 適切な候補がない場合は、調査者が表現を修正する、質問群 X から別の質問を選び、尋ねるか、固定質問群 Z に移行する. 特に、研究倫理上の妥当性を満たさない候補は、情報の有用性が高くても採用しない. また、LLM が生成した発言に不要な虚偽や過度な犯罪関与の示唆が含まれる場合は、調査者が削除または緩和してから送信する.

#### 3.5 ステップ 4: 対話ルールの改善

ステップ 4 では、ロールプレイで明らかになった問題に基づいて対話ルールを改善する. 改善では、対話を継続することよりも倫理的妥当性を優先する. したがって、回避表現を追加しても犯罪行為への加担や第三者への危害を避けられない場合は、対話継続の方針ではなく中止条件として明文化する. また、同じ回避応答を繰り返すことで不自然さや疑念が高まる場合も、無理に会話を続けず撤退する条件として扱う.

改善後の対話ルールは、再びステップ 3 のロールプレイで検証する. この反復により、調査者は実際の攻撃者に接触する前に、想定可能な範囲で安全な応答方針を準備できる. ロールプレイで対話ルールの範囲内に収まることが確認できた場合にのみ、ステップ 5 の実対話へ進む.

#### 3.6 ステップ 5: 本物の攻撃者との対話実行

ステップ 5 では、安全性を確認した対話ルールに基づき、調査者が本物の攻撃者と接触する. 本手法では、LLM が生成した発言候補を自動送信しない. 調査者が各候補を確認し、必要に応じて修正したうえで送信する Human-in-the-loop の運用を採る. これにより、LLM の生成能力を活用しつつ、最終的な倫理的・戦略的判断は人間が担う.

対話の終了条件は二つである. 第一に、収集目標が達成された場合である. 目的情報が得られた時点で、それ以上の深掘りや雑談を行わず、自然な形で対話から離脱する. 第二に、倫理的レッドラインを越える要求を受けた場合、または例外処理でも安全に対応できない場合である. この場合、情報獲得を断念し、対話を中止する. 本手法では、対話の継続性よりも、調査者、対象者、第三者に対する危害の最小化を優先する.

以上のステップ 1～5 により、本手法は、公開情報に基づく収集目標の設定、対話ルールの事前構築、ロールプレイによ

る検証、ルール改善、Human-in-the-loop による実対話を一連のプロセスとして接続する。具体的なモデル、プロンプト形式、対象抽出方法、固定質問群、およびロールプレイによる例外処理の策定手順は、実証実験の設定として第 5. 章で述べる。

## 4. 実際の攻撃者との対話

本実験の調査者は、情報セキュリティを専攻し、メンロレポートに基づく研究倫理を学習した大学院生 2 名であり、いずれも本論文の著者である。2026 年 5 月 14 日から同年 5 月 24 日にかけて、Telegram の公開グループ上でスパムツール、なりすまし電話ツール等の販売を宣伝する攻撃者およびその連絡先 10 件を対象に、購入希望者を装って接触を試みた。攻撃者との対話はすべて英語で行った。対象の選定には TelegramDB [11] を用い、「Spam」「SMTP」等の語で検索して得られた宣伝投稿者のうち、ダイレクトメッセージで連絡可能な 10 名を対象とした。本実験では、対話ツリー生成 LLM には OpenAI の gpt-5.5 (実験実施時点の最新版) を、疑似攻撃者 LLM には OpenAI の (gpt-4o, temperature 0.7) を用い、Python スクリプトで API 経由の処理を自動化した。一連の分析と対話候補は JSON 形式で構造化して出力させた。攻撃者の公開情報ごとに出力された対話ツリーは平均 54 ノードの規模に及び、起点となる質問群 X (約 6 件)、想定される相手の予測返答群 A (約 12 件)、さらにその返答に応じた次なる質問群 Y (約 36 件) の 3 階層で構成された。対話ツリー LLM のペルソナとして「小規模な SMS/メール配信案件を扱う実務者」を設定し、「前業者の劣悪なサポートや頻繁なアカウント停止により不利益を被ったため、今回は安定した新たなインフラ提供元を慎重に探している」という背景ストーリーをプロンプトに組み込んだ。これにより、送信者 ID の偽装可否やプロバイダ停止時の交換ポリシーといった踏み込んだ質問も、慎重な購入検討者としての自然な振る舞いに位置づけられるようにした。一方、疑似攻撃者 LLM のプロンプトには、フィッシングキットなどを販売するサイバー犯罪ベンダーの役割を設定した。対話のリアリティを高めるため、利益を求めるビジネスライクな性格に加え、無駄な挨拶を省き、匿名掲示板や Telegram 特有のラフな英語の言葉遣いを用いるといったペルソナ情報を組み込んだ。これにより、実際の販売者のようなドライで実用性を重んじる振る舞いで対応できるようにした。

### 4.1 ステップ 1. 収集目標の設定

本実験ではスパムツールの販売者を対象に、犯罪エコシステム解明の鍵となる決済手段の特定を調査目的とした。

### 4.2 ステップ 2. 対話ルールの初期設定

調査目的を達成するため、調査者が段階的に投入する固定質問群 Z を事前に用意した。固定質問群 Z は、Z1: 価格、Z2: 購入から利用までの手順、Z3: 対応する支払い方法、Z4: 送金先アドレス、の 4 つである。Z2 は決済アドレスの収集に必須ではないが、取引の流れの中で自然に尋ねられ、OSINT では得にくい情報であるため調査対象に含めた。

### 4.3 ステップ 3. ロールプレイによる安全性の検証

例外処理の事前検証として、疑似攻撃者 LLM に「警戒心が

強く専門用語を多用する攻撃者」を演じさせるロールプレイを実施した。ロールプレイを通じて、攻撃要件 (ツール・標的地域・ボリューム・プラン) の決定を迫られるケース等、固定質問群や予測ツリーで対応しきれない状況を洗い出した。ロールプレイに先立ち、提案手法に従って予測ツリーを事前に生成した。公開投稿を起点として質問群 X を 5 件または 6 件、各 X に対する予測返答 A を 3 件ずつ、さらに各 A への返信候補である質問群 Y を 3 件ずつ用意した。LLM には、宣伝投稿を 1 行ごとに分析させただけで、予測ツリーに基づく返信候補を「リスク回避」「自然な対話維持」「情報探索」の 3 方針で提示させ、各候補の倫理的注意点も併せて出力させた。解説は日本語、チャット候補文は地下フォーラム調のカジュアルな英語で出力させた。この予測ツリーの作成には約 1 時間を要した。対話は調査者が質問群 X を構成する質問から一つ発言を選び、送信することで始まる。その返信が予測返答群 A に含まれる返信候補のいずれかと一致していた場合、対応する質問群 Y から先述した基準で発言を選択する。予測返答群 A に返信候補がなかったり、質問群 Y に返信が来た場合、質問群 X か固定質問群 Z から別の質問を選ぶ。一つの対話の中で質問群 X に含まれる質問を尋ねる回数は最大 2 回までとした。

### 4.4 ステップ 4. 対話ルールの改善

ロールプレイで判明した課題に対し、例えば、使用ツールや標的を尋ねられた際は明言を避け、価格次第だと濁すといった対応策を例外処理として追加した。ロールプレイとルールの改善を計 3 回実施し、対応不能なケースが生じなくなったことを確認して実対話へ移行した。この例外処理の策定には約 3 時間を要した。

### 4.5 ステップ 5. 本物の攻撃者との対話実行

対話では、LLM が生成した発言候補を自動送信せず、2 名の調査者が倫理的妥当性、自然さ、情報の有用性の 3 基準で取捨選択し、必要に応じて手動修正してから送信した。たとえば、LLM がペルソナを過剰に反映して不要な虚偽を含む発言を生成した場合には、調査者が該当部分を削除した。また、暗号資産アドレス等の決済手段が提示された時点を目的達成とし、それ以上の機能の深掘りや雑談は行わず、「検討して後日連絡する (I'll think about it and contact you later.)」といった購入保留の自然な返答を最後に送信して対話を終了した。例外処理が破綻した場合や、倫理的に応答できない要求を受けた場合は、即座に対話を中止する方針とした。以降、各販売者を表 1 の番号で参照する。

## 5. 実際の攻撃者との対話による結果

本章では、前章の実装に基づき実施した実証実験の結果を述べる。本実験は、Telegram 上の不正スパムツール販売者 10 名に対する探索的な事例研究である。以下に述べる価格・通貨・悪用サービス・標的国等は販売者の自己申告であり、履行や実態は検証していない。また対象は販売を能動的に宣伝する者に限られるため、購入希望者への応答性には自明な面があり、地下市場全体への一般化はできない。これらの留意点は本章に共通するものとして以後繰り返さず、解釈や含意は第 6. 章

で論じる。以降、各販売者を表 1 の番号で参照する。

### 5.1 会話の成立状況と対話ツリーからの発言選択状況

接触した 10 名全員と会話が成立し、発話の総数は 174 (調査者 56, 販売者 118) であった。このうち 7 名から暗号資産送金先アドレスを取得した。販売者ごとの統計を表 1 に示す。また、実際の発言と対話ツリー内の想定発言が完全に一致することはなく、両者の対応関係の特定には人間の判断を要した。しかし、判断に迷うことはなく、スムーズに処理できた。

### 5.2 HUMINT で得られた情報

#### a) 商品・価格情報

対話を通じて、SMS 配信パネル、SMTP (メール大量配信基盤)、SIP/VoIP 通話、および不正に取得されたとみられる Microsoft 365 アカウントといった商品カテゴリと、その価格体系が得られた。価格は、一括 (SIP USA \$300 / 他 \$260)、月額アカウント (Microsoft 365 \$9 ~ \$85/月)、送信単価 (SMS \$0.01 ~ \$0.04/通、SMTP は 30k ~ 100k 通あたり \$120 ~ \$250)、および定額無制限 (月額 250 ユーロの無制限 SMS) の 4 類型に整理できる。特に、国別レートでの SMS ルート卸売や、ユーロ建てで送信量に上限を設けない課金設計もみられた。

#### b) 暗号資産送金先アドレス

7 件の暗号資産送金先アドレス (Bitcoin 5 件: bech32 形式 4・legacy 形式 1, TRON 上の USDT (TRC20) 2 件) を取得した。ただし多くの販売者は複数の暗号資産に対応すると述べており、どの通貨のアドレスを得たかは調査者が示した支払意思によるため、本内訳は特定通貨の優勢を示すものではない。

#### c) 悪用される正規サービス

踏み台として悪用される正規サービスとしては、SMTP (Amazon SES, SendGrid, Ionos, AWS)、Microsoft 365, SIP/VoIP プロバイダ、A2P SMS のキャリア接続が発言中に挙げられた。

#### d) 標 的 国

言及された標的地域は USA (最多)、UK, Australia, Spain, および Germany・Italy・France であり、日本・韓国・中国等のアジア市場への言及は確認されなかった。

### 5.3 販売者の行動・取引運用

調査者の対話を通じて観察された、販売者の応答や取引運用の特徴を、対話ログをもとに整理した。

#### a) 質問への回答状況

価格・手順・送金先アドレス等を明示的に問う質問 (計 52 件) への応答を整理すると、はぐらかして回避する応答は観測されず、無応答は 2 件で、いずれも対話末尾で返信がなかった。多くの販売者が価格・ルート・送金先アドレス・手順を速やかに開示し、積極的な身元確認はほとんど見られなかった。

#### b) 応答速度と対話期間

対話期間 (表 1) の差は大きく、最短 30 分から最長 10 日であった。対話期間が長くてもアドレス取得に至る例があり、1 通あたりの返信の速さ (返信時間中央値) と取引全体の所要時間は必ずしも連動しない。これは個々の返信が速くても、やり取りの合間に長い空白が生じるためである。

#### c) 取引運用の形態

観測範囲では決済は暗号資産に限られ、対話中に法定通貨や

銀行口座への言及はなく、第三者の決済代行を介す運用も観測されなかった特に、販売者 4 は「仲介者を介さず取引する (I work without intermediaries)」と明言した。支払確認方法は異なり、多くはスクリーンショットや受領証を求めた一方、トランザクションハッシュでの検証を要求する例もあった。購入後の利用開始までの所要時間 (10 ~ 30 分) の提示や初期設定の代行など、一般の顧客サポートに類する対応も複数確認された。

#### d) 定型句の共有

対話結果を目視で対照したところ、country sms do you need (販売者 1, 6) をはじめ連続 3 語以上が一致する定型句が複数の販売者間で確認され、営業上の言い回しが共有されている可能性が示唆された。ただし、対象の語彙が限られるため、短い一致は偶然の可能性も否定できない。

#### e) 対話を中止した事例

アドレス入手に至らなかった 3 名は、いずれも事前の取り決めである、中止基準や例外処理では返信できない要求を受けたため、対話を打ち切った。販売者 4 は宣伝 (攻撃) 目的の表明 (What do you want to advertise?) を求めたが、これは取り決め上応答を用意していない要求であった。販売者 5 は購入前のアカウントアクセス供与によるテスト (I can test for you and give you access to account) を申し出たが、これは取り決めの想定外であり返信しなかった。販売者 6 は予算額の提示を求めたが、応じるには同じ回避の対応の反復が必要となり、取り決め上それ以上返信できず打ち切った。

### 5.4 実際の対話時の倫理的配慮

本節では、実験を通じて倫理面で観測された事実を述べる。実験設計上の倫理的考察については第 7. 章で論じる。

また、前節で述べたとおり、倫理的に応答できない逆質問を受けた 3 件では、調査者が応答を送信せず対話を中止しており、倫理的制約が実際の対話の打ち切りという形で機能した。

## 6. 考 察

本章では、前章の結果を踏まえ、提案手法の有効性とそこから得られた知見を考察する。なお、提案手法の倫理的妥当性に関する詳細な検討は第 7. 章で別途論じる。

### 6.1 提案手法の有効性と調査者の負担

本手法を用いることで、接触した 10 名全員と会話が成立し、うち 7 名から OSINT では取得困難な暗号資産送金先アドレスを取得できた。本手法の利点は、HUMINT の実施に必要な専門知識の障壁を下げうる点にある。攻撃者コミュニティ特有の隠語の解釈や難読化された宣伝文の理解を LLM に事前に担わせ、文脈に即した発言候補をあらかじめ用意することで、調査者は対話のたびに発言をゼロから考案する必要がなくなり、専門知識を十分に持たない調査者でも対話を進めやすくなる。

加えて、対話中の作業が「考案」から候補の「選択・微修正」へと変わること、および本実験を 2 名で実施し発言の選択や中止を相互に確認できたことは、調査者の認知的・心理的な負担の軽減につながったと感じられた。同一の調査者が携わった先行研究 [8] と比べても、問題のある発言を送信する不安が抑えられ、主観的にはより安心感をもって対話を進められた。



表 1: 販売者 10 名の対話統計と暗号資産送金先アドレスの取得状況

| No. | 調査者<br>発話数 | 販売者<br>発話数 | 対話対象商品             | 返信時間<br>中央値 [分] | 対話期間<br>† [時間] | アドレス<br>入手 | 取得アドレス種別 /<br>中止した理由 ‡ | 提示された対応通貨             |
|-----|------------|------------|--------------------|-----------------|----------------|------------|------------------------|-----------------------|
| 1   | 6          | 12         | SMS パネル            | 312             | 242.0          | ✓          | BTC (bech32)           | BTC/ETH/USDT/LTC      |
| 2   | 6          | 15         | SIP (VoIP)         | 1               | 0.5            | ✓          | BTC (legacy)           | BTC/USDT              |
| 3   | 10         | 17         | SMS, Microsoft 365 | 1               | 1.6            | ✓          | USDT (TRC20)           | USDT (TRC20)          |
| 4   | 2          | 3          | メール / SMS          | —               | —              | —          | 中止 (倫理上対応不可)           | —                     |
| 5   | 3          | 7          | SMS, SMTP          | —               | —              | —          | 中止 (倫理上対応不可)           | —                     |
| 6   | 2          | 6          | SMS, メール           | —               | —              | —          | 中止 (同一対応の反復を回避)        | —                     |
| 7   | 6          | 10         | SMS ルート            | 1               | 48.0           | ✓          | USDT (TRC20)           | USDT (TRC20)          |
| 8   | 5          | 19         | SMTP               | 0               | 0.6            | ✓          | BTC (bech32)           | BTC/ETH/USDT          |
| 9   | 8          | 13         | SMS ルート            | 3               | 18.9           | ✓          | BTC (bech32)           | BTC/ETH/USDT          |
| 10  | 8          | 16         | SMS ゲートウェイ         | 2               | 1.3            | ✓          | BTC (bech32)           | BTC/ETH/TRON/LTC/USDT |

返信時間中央値は販売者が最初に返信するまでの所要時間の中央値 (分, 0 分は 30 秒未満). 時間指標と対話期間 († = 最初の接触から最後のやり取りまでの時間) は, アドレス取得まで到達した 7 名のみ示し, 早期に中止した販売者 (No. 4, 5, 6) は取引の成否を表さないため「—」とした. ‡ はアドレス入手者には取得した種別を, 未入手者には中止理由を示す (詳細は本文). 「提示された対応通貨」は販売者が対応可能と述べた通貨で, 取得アドレス種別はそのうち調査者が支払意思を示した通貨に対応する.

接触した 10 名全員と会話が成立し, はぐらかしや積極的な身元確認もほとんど見られなかった. この高い応答性は, 第 3. 章で述べたペルソナ設計・公開投稿の事前理解・地下フォーラム調の口調生成といった設計が, 調査者を「質問ばかりで買わない不審な人物」ではなく同コミュニティの一員として自然に見せたことによる可能性がある.

## 6.2 中止・例外処理プロトコルの妥当性

本実験では, 実対話の前に擬似攻撃者 LLM とのロールプレイで例外処理を策定した (第 5. 章). ロールプレイでは送信ボリューム・予算・用途／標的・支払い方法・プラン選択といった想定外の質問にはぐらかしで対応でき, 中止には至らなかった. すなわちロールプレイは主に, 中止を避けるための例外処理の構築に寄与した.

実対話でも想定外要求の多くがこの範囲に収まり, 価格・プラン・支払い方法の探りははぐらかしや質問群 Z への誘導で処理して 7 名で決済情報を得た. 中止に至った 3 名のうち, 販売者 6 と販売者 4 はロールプレイで想定した類型に対応し, 攻撃者の要求が倫理的に問題となる場合に中止するという制御方針が機能したことを示す.

一方, 販売者 5 はロールプレイ未想定の新たなケースであり, 個別の例外処理ではなく, 攻撃の実行に加担しないという上位の安全規則に基づいて中止した. これは, 事前策定が想定外要求の多くをカバーしう一方, 最終的には調査者の倫理的判断と中止規則が安全性を担保することを示す. 本手法は安全性を担保する反面, 機微情報の獲得を断念せざるを得ない場面も生じ, 安全性を損なわず対話を継続する方策の検討は今後の課題である.

## 6.3 観測された市場構造と OSINT との位置づけ

調査結果から, 本対象コミュニティでは価格が一括・月額アカウント・送信単価・定額無制限の 4 類型に分かれ, SMS に加え SMTP・SIP/VoIP・Microsoft 365 と幅広い商材が, 買い手のニーズに応じて扱われている実態がうかがえる. ただし,

観測できたのは調査者が尋ねた商材に限られ, 留意が必要だ.

こうした情報のうち, とりわけ送金先アドレスのような決済手段は, 公開情報の分析では到達し難く, 個別対話を通じてでなければ開示されにくい. 本研究で 7 件の送金先アドレスを対話により取得できたことは, HUMINT が OSINT を補完し, 公開情報では到達し得ない層のインテリジェンスを獲得しうることを具体的な事例で示すものである. なお, 両手法が獲得する情報の差分の定量的な評価は今後の課題である.

## 6.4 本研究の限界

本研究の対象は特定のプラットフォームの 10 名に限られるため一般化は保証されない. また, 本手法は調査者の言語運用能力や LLM の生成品質に依存しており, これらが対話の成否や安全性に与える影響は切り分けられていない. さらに, 倫理面の問題発言の有無は 2 名の調査者による対話中および事後の相互確認に留まり, 独立した監査や評価者間の一致率の算出は行っていないため, 客観性には限界がある.

## 7. 倫理的考慮

本研究は, 実在する攻撃者との対話を伴うため, 研究倫理上の配慮が不可欠である. 本章では, メンロレポート [2] の 4 原則を指針として, 研究対象者・第三者・調査者の人権尊重と潜在的风险の低減のために講じた対策を, ステークホルダーごとに述べる. 本研究は, 購入希望者を装う欺瞞を含み対象者の同意を取得しない設計である. この設計を含めて, 対象の選定方針・送信しうる発言の範囲・対話中止の基準・取得データの管理方法を事前に文書化し, 実施に先立ち所属機関 IRB の倫理審査を受け, 承認を得た. また第 3. 章のとおり, 実対話の前に擬似攻撃者 LLM とのロールプレイを繰り返し, 倫理的に問題のある発言を誘発しうる状況と回避策を洗い出した.

### 7.1 研究対象者への配慮

対象としたのは, Telegram の公開グループ上で不正ツールの販売を自ら宣伝している者であり, 犯罪行為を能動的に行っ

ている主体である。対話は購入希望者を装って行ったが、欺瞞は機微情報の取得に必要な最小限にとどめ、相手に金銭的・心理的な実害を与える行為や過度な働きかけは行っていない。

本研究は対象者からのインフォームド・コンセントを取得していない。メンロレポートは、同意取得が研究遂行を著しく困難または不可能にする場合に例外的な免除を認めている。先行研究[8]では、目的を開示する同意ベースの手法で攻撃者が警戒・離脱し同意率が0%であったことが示されており、目的を秘匿した接触が不可欠な本研究はこの免除要件に該当する。

また、事後に研究目的や欺瞞を明かすデブリーフィングも実施していない。稼働中の犯罪行為主体に対してこれを実施すれば、「騙された」という反発に加え、調査への警戒心を高める可能性も考えられる。さらには調査者への追跡や報復を誘発しかねず、対象者・調査者双方のリスクをかえって高める可能性も否定できない。上記の理由から本研究では研究目的を明かさない方針を採用した。なお、取得したデータに含まれる販売者のハンドル名・連絡先・暗号資産アドレス・スクリーンショット等、特定の個人を識別しうる情報は本論文には一切掲載していない。

## 7.2 第三者および社会への配慮

本研究の便益は、OSINT では到達困難な決済手段等の脅威インテリジェンスを獲得し、防御や対策の検討に資する点にある。一方、攻撃者との対話には犯罪行為への加担や攻撃の助長といったリスクが伴う。このリスクを低減するため、送信する発言は LLM が生成した候補のうち 3 基準を満たすもののみを調査者が人手で選択し、取引意思を示しつつも実際の送金は一切行わず、倫理的に応答できない要求を受けた場合は対話を中止する方針を遵守した。これらの措置のもとで問題のある発言が送信されなかったことは、5.4 節に示したとおりである。

また、販売対象には侵害されたとみられる Microsoft 365 アカウントや正規のメール配信サービス (Amazon SES 等) など第三者の資産が含まれていたが、本研究は販売者の言及を記録したのみで購入・アクセス・再利用は一切行っておらず、第三者の資産をさらなる危害に晒していない。取得した送金先アドレスや悪用インフラの情報は稼働中の犯罪活動に関わるため、外部機関への提供は被害低減に資する可能性がある一方で対象の特定や二次利用の懸念があり、また本研究が摘発を目的としないことから、研究目的のみに用いて厳重に保管・分析し、外部提供は行わない方針とした。

## 7.3 調査者への配慮

攻撃者との対話には、報復や追跡といった調査者側のリスクも伴うため、実験は仮想環境で行った。また、対話は 2 名の調査者で実施し、発言の選択と対話中止の判断を相互に確認することで、単独実施に伴う心理的負担や判断の偏りを軽減した。また、調査者は購入希望者を装う匿名のアカウントを用い、実名・所属・個人を特定しうる情報を対話中に開示しなかった。さらに、悪意ある攻撃者からの報復の可能性を考慮し、一連の対話は仮想環境上で実施することで、研究者が所有する機器への損害リスクを排除した。このような対応により、我々はステークホルダーへ生じうるリスクを最小化した。ま

た、この実験を行うことで HUMINT の実証価値を示すことができ、生じうるリスクよりも大きな恩恵が得られると判断し、この実験の実施、論文の公開に至った。

## 8. 今後の展望

本研究は倫理的配慮を尽くしリスクの最小化に努めた。今後の展望についても、社会的な恩恵がリスクを大きく上回ると判断される場合に限り実験を行う。今後の課題として、安全性を損なわず多様な発言に対応し、獲得を断念した機微情報も取得できるよう例外処理や対話制御方策の拡充が求められる。また、擬似攻撃者 LLM のリアリティ評価や、対象をマルウェア等の販売者に広げた汎用性の検証、あえて「初心者」を装うことで、手口の詳細や運用ノウハウを相手からより深く引き出せるかについても検討する。

**謝辞** 本研究の一部は、N E D O (国立研究開発法人新エネルギー・産業技術総合開発機構) の委託事業「経済安全保障重要技術育成プログラム／先進的サイバー防御機能・分析能力強化」(JPNP24003) によるものである。

## 文 献

- [1] 鈴木涼介, 川口大和, インミンパバ, 山岡裕明, 吉岡克成. サイバー攻撃者とのテキストベース対話による情報収集フレームワーク～法と研究倫理への配慮と llm 活用～. 電子情報通信学会技術研究報告, Vol. 124, No. 422, pp. 391–398, mar 2025.
- [2] The menlo report: Ethical principles guiding information and communication technology research. <https://www.dhs.gov/sites/default/files/publications/CSD-MenloPrinciplesCORE-20120803-1.pdf>, August 2012.
- [3] Christopher Hadnagy. *Social Engineering: The Art of Human Hacking*. Wiley, 2010.
- [4] Gary T. Marx. *Undercover: Police Surveillance in America*. University of California Press, 1988.
- [5] Alice Hutchings and Thomas J. Holt. Interviewing cybercrime offenders. *JQJC*, Vol. 7, No. 1, pp. 75–94, fall 2018.
- [6] Hossein Siadati, Haadi Jafarian, and Sima Jafarikhah. Send to which account? evaluation of an llm-based scambaiting system. <https://arxiv.org/abs/2509.08493>, 2025. arXiv:2509.08493.
- [7] 長山侑央, 久保颯汰, インミンパバ, 森辰則, 吉岡克成. Humint 対話における倫理監視 llm の構築に向けて～メンロレポートに基づくチェックリストの活用～. コンピュータセキュリティシンポジウム 2025 論文集, oct 2025.
- [8] 久保颯汰, 長山侑央, インミンパバ, 森辰則, 吉岡克成. インフォームド・コンセントに基づく telegram 上の人的情報収集の実施可能性の検証. コンピュータセキュリティシンポジウム 2025 論文集, oct 2025.
- [9] 青砥陸, インミンパバ, 吉岡克成. 類似チャンネル提示機能を活用した telegram におけるサイバー犯罪関連チャンネルの発見と分析. 電子情報通信学会技術研究報告, Vol. 124, No. 422, pp. 399–406, mar 2025.
- [10] Assaf Morag. The phishing kits economy in cybercrime markets. Flare Systems, 2026. <https://flare.io/learn/resources/phishing-kits-economy-cybercrime>.
- [11] PRISMALABS SRLS. TgDB - the ultimate OSINT search engine for telegram. <https://www.tgdb.org/page/index>, 2026. Accessed: 2026-06-08.