

# Discord上のサイバー犯罪関連メッセージに対する LLMを用いた情報収集・分析システム

宮本 直樹<sup>†</sup> 川口 大翔<sup>††</sup> インミンパパ<sup>††</sup> 吉岡 克成<sup>†††,††</sup>

<sup>†</sup> 横浜国立大学大学院環境情報学府

<sup>††</sup> 横浜国立大学先端科学高等研究院

<sup>†††</sup> 横浜国立大学環境情報研究院

E-mail: <sup>†</sup>miyamoto-naoki-sz@ynu.jp, <sup>††</sup>{kawaguchi-yamato-bx,yinminn-papa-jp,yoshioka}@ynu.ac.jp

**あらまし** 近年, Discord や Telegram といった匿名性の高いメッセージングアプリがサイバー犯罪の温床となっている. 特に Discord は, 高い匿名性と不特定多数との接続の容易さから, 多様な犯罪活動に悪用されている. この問題に対し, OpenAI API を利用して Discord 上のサイバー犯罪情報を収集するシステムが提案されているが, 従来手法には2つの課題が存在する. 第一に, ユーザが指定した特定のサイバー犯罪カテゴリからキーワードを生成し, それに合致するメッセージのみを分析対象とするため, 指定されなかったカテゴリの犯罪活動や, キーワードに含まれない未知の表現が検知から漏れ, サイバー犯罪活動の全体像を把握することが困難である. 第二に, クラウド型の大規模言語モデル (LLM) に依存しているため, 個人情報を含むメッセージの処理が困難である. 本研究では, 検知の網羅性向上とプライバシー保護の両立を目的とし, キーワードマッチングに依存せず, ローカル LLM を用いて収集した全メッセージを直接カテゴリ分類する新たな情報収集・分析システムを提案する. 本システムは, ローカル LLM を用いて犯罪の疑いがあるサーバを判定した上で参加し, 取得できた内部の全メッセージをカテゴリ分類する. 実証実験では, 1,090 件のサーバから 532,988 件のユニークなメッセージを収集し, 19,806 件のサイバー犯罪関連メッセージを抽出した. ローカル LLM を用いた分類精度は, サーバ識別の F1 スコアが 0.89, メッセージ識別の F1 スコアが 0.84 であった. 分析の結果, コンピュータデータおよびシステムの機密性・完全性・可用性に対する犯罪, ならびに著作権に関する犯罪に関連するメッセージが多く観測され, 他の Discord サーバや外部プラットフォームへのリンクも多数投稿されていることが確認された.

## LLM-Based Information Gathering and Analysis System for Cybercrime-Related Messages on Discord

Naoki MIYAMOTO<sup>†</sup>, Yamato KAWAGUCHI<sup>††</sup>, Yin Minn Pa Pa<sup>††</sup>, and Katsunari YOSHIOKA<sup>†††,††</sup>

<sup>†</sup> Graduate School of Environment and Information Sciences, Yokohama National University

<sup>††</sup> Institute of Advanced Sciences, Yokohama National University

<sup>†††</sup> Faculty of Environment and Information Sciences, Yokohama National University

E-mail: <sup>†</sup>miyamoto-naoki-sz@ynu.jp, <sup>††</sup>{kawaguchi-yamato-bx,yinminn-papa-jp,yoshioka}@ynu.ac.jp

**Abstract** Anonymous platforms like Discord are increasingly exploited for cybercrime. Existing intelligence collection systems using cloud-based LLMs face two challenges: privacy risks when processing personal data, and unscalable keyword matching that misses slang and novel threats. To address this, we propose a keyword-independent system utilizing a local LLM to preserve privacy and enhance detection coverage. Our system automatically identifies suspected cybercrime servers using a local LLM, after which analysts manually join them and the system categorizes all collected messages. In our evaluation, the system analyzed 532,988 messages from 1,090 servers, extracting 19,806 cybercrime-related messages. The local LLM achieved F1-scores of 0.89 for server identification and 0.84 for message classification. Analysis revealed a prevalence of copyright infringements and offenses against the confidentiality, integrity, and availability of computer data and systems, frequently accompanied by links to external platforms and other Discord servers.

## 1. はじめに

近年、メッセージングプラットフォームである Discord は、その手軽さから全世界でデイリーアクティブユーザー数 9,000 万人以上 [1] を抱えるまでに普及している。一方で、その高い匿名性とコミュニティ形成の容易さが悪用され、暗号資産詐欺 [2] やヘイト活動 [3] など、多岐にわたるサイバー犯罪の温床となっている。Discord 上のサイバー犯罪を調査・分析する上では、プラットフォーム特有の構造に起因するいくつかの困難性が存在する。第一に、サーバ発見の困難さである。Discord にはプラットフォーム内部に網羅的なサーバ検索機能が存在せず、サーバへの参加は発行された招待リンクに依存している。そのため、サーバへの入り口が他のサーバや SNS、ディレクトリサイトなどに分散しており、悪意あるサーバを効率的に探し出すことが難しい。第二に、サーバ参加時の制約である。多数のサーバの招待リンクを発見できたとしても、参加時には CAPTCHA 等の認証が求められる場合が多く、その手続きを自動化することは困難であるため手動で行う必要がある。加えて、1 アカウントあたりのサーバ参加上限数による制約も存在するため、コストの観点から無差別に多数のサーバへ参加を試みることは現実的ではない。第三に、サーバ単位の分析の困難さである。仮にサーバへ参加できたとしても、内部には多様なユーザの発言に加えて、Bot の自動通知や日常的な雑談なども混在している。そのため、サーバ内の投稿の一部のみをサンプリングして分析するだけでは、サーバ全体の性質やサイバー犯罪との関連性を正確に評価することが難しい。こうした Discord 上の脅威に対する情報収集手法として、川口らは OpenAI API を利用した Discord 上の情報収集システム [4] を提案している。同システムは、ユーザが入力したカテゴリに基づき OpenAI API を用いてキーワードを生成し、該当する Discord サーバの探索からサーバへの参加、メッセージの収集、分析を行うものであり、特定キーワードに関連する犯罪情報の効率的な発見に寄与している。しかし、この従来手法には大きく 2 つの課題が存在する。第一の課題は、ユーザが指定した特定のサイバー犯罪カテゴリからキーワードを生成し、それに合致するメッセージのみを分析対象とする点である。この方式では、指定されなかったカテゴリの犯罪活動や、キーワードに含まれない未知の犯罪手法・隠語・文脈的な表現を用いたメッセージが検知から漏れるため、サイバー犯罪活動の全体像を把握することが困難である。第二の課題は、クラウドベースの大規模言語モデル (LLM) に依存している点である。これにより、分析対象に個人情報が含まれる場合、プライバシー保護や情報漏洩リスクの観点から制限がかかる。

そこで本研究では、これらの課題を解決し、Discord 上におけるサイバー犯罪関連情報の検知網羅性を向上させる新たな収集・分析システムを提案する。本システムでは、前述したサーバ発見と参加の制約を克服するため、まず複数の Discord ディレクトリサイトからサーバ情報 (サーバ名、説明文、招待リンク) を収集する。次に、ローカル LLM を用いて、これら参加前のメタ情報からサイバー犯罪に関連する疑いが強い

サーバを事前に推定・識別する。このようにして厳選したサーバへ手動で参加したのち、雑談や Bot 通知が混在する中からサイバー犯罪関連情報を正確に抽出するため、内部のメッセージを全件収集する。そして、再びローカル LLM を用いて各メッセージを 1 件ずつ分析・分類する。ローカル LLM の活用により、情報漏洩のリスクを排除しつつ、キーワードフィルタリングに依存しない全件分析を実現した。

結果として、本研究ではサーバ検索サイトから収集した 107,122 件のサーバ情報から、1,298 件のサイバー犯罪に関連すると思われる Discord サーバに参加を試み、そのうち 1,090 件の Discord サーバから計 19,806 件のサイバー犯罪に関連するメッセージを識別することに成功した。抽出されたメッセージのサイバー犯罪カテゴリ内訳は、コンピュータデータおよびシステムの機密性・完全性・可用性に対する犯罪が 8,796 件 (44.4%)、著作権に関する犯罪が 6,075 件 (30.7%)、コンピュータを介した犯罪が 3,891 件 (19.6%)、コンテンツに関連する犯罪が 1,002 件 (5.1%)、複合的な犯罪が 42 件 (0.2%) であった。ローカル LLM を用いた分類精度において、実際にサーバへ参加することなく検索サイト上のサーバ情報のみを用いたサーバ識別でありながら、F1 スコア 0.89 という高い精度を達成した。また、参加後に収集したメッセージの識別においても F1 スコア 0.84 を達成している。本提案手法により、ボットネットの宣伝や不正アクセスの売買、違法コンテンツの流通など多様な犯罪活動が見られたほか、URL からなる Discord サーバ間、異なるプラットフォーム間のネットワーク構造を発見するに至った。

## 2. 関連研究

### 2.1 複数のサイバー犯罪カテゴリに関する研究

川口ら [4] は、Discord 上のサイバー犯罪情報を収集する 6 段階のシステムを提案した。まず、ユーザが取得対象・関連・除外のカテゴリを指定し、OpenAI API がそれに基づくキーワードを生成する。次に、Discord ディレクトリサイトからサーバ情報を収集し、OpenAI API で対象サーバを絞り込む。サーバへの参加はリアクションやボット検証を伴うため手動で行い、参加後にメッセージを全件収集する。最後に、キーワードを含むメッセージに対し OpenAI API でカテゴリ該当性およびサーバの対象適合性を判定する。この手法により、参加した 55 件のサーバから約 128 万件のメッセージを取得し、28 件が対象サーバと判定された。その中にはクレジットカード情報の販売や盗取された認証情報の共有といった事例が確認された。

### 2.2 特定のサイバー犯罪カテゴリに関する研究

Nizzoli らによる研究 [2] では、X (旧 Twitter)、Discord、Telegram における暗号資産関連のサイバー犯罪を調査した。Twitter 上の投稿から Discord や Telegram への招待リンクを収集し、スノーボールサンプリングにより連鎖的にサーバへ参加することで、SNS 間・チャンネル間のネットワーク構造を可視化し、2 種類の暗号資産関連詐欺を明らかにした。また、Heslep らによる研究 [3] では、Discord ディレクトリサイトに掲載されているサーバのタグや説明文を分析し、ナチズムや白人至上主

義などヘイト活動に関連するサーバが数千件規模で存在することを明らかにした。

### 2.3 サイバー犯罪のカテゴリ分類に関する研究

Tsakalidis らによる研究 [5] では、ブダペスト条約 [6] の基本理念に基づき、複合型犯罪を加えた以下の 5 カテゴリを提案した。

カテゴリ A: コンピュータデータおよびシステムの機密性・完全性・可用性に対する犯罪。不正アクセスや不法な改ざん等が含まれる。

カテゴリ B: コンピュータに関連する犯罪。伝統的な犯罪の手段としてコンピュータシステムを利用する行為が含まれる。

カテゴリ C: コンテンツに関連する犯罪。児童の性的搾取、違法ポルノ、サイバーいじめ等が含まれる。

カテゴリ D: 著作権に関する犯罪。著作権侵害や商標権侵害が含まれる。

カテゴリ E: 複合的な犯罪。サイバー資金洗浄やフィッシング等、単一の行為に複数の犯罪要素を含むものである。

### 2.4 既存研究に対する本研究の位置づけ

前述の既存研究に対し、本研究は以下の 2 点で差別化される。第一に、分析対象の網羅性の向上である。川口ら [4] の手法では、ユーザが指定した特定のサイバー犯罪カテゴリからキーワードを生成し、合致するメッセージのみを分析対象とするため、指定外のカテゴリや未知の表現による犯罪活動が検知から漏れ、全体像の把握が困難であった。また、Nizzoli ら [2] や Heslep ら [3] の研究も、それぞれ暗号資産詐欺やヘイト活動といった特定カテゴリに焦点を当てたものである。これに対し本研究では、Tsakalidis ら [5] の 5 カテゴリ分類を採用し、キーワードマッチングに依存せず収集した全メッセージをローカル LLM で直接分類することで、サイバー犯罪活動の網羅的な把握を目指す。第二に、プライバシー保護への対応である。川口ら [4] の手法ではクラウド型 LLM を使用しており、個人情報を含むメッセージの処理にリスクが伴う。本研究ではローカル LLM を用いることで、外部への情報送信を排除し、プライバシーを保護しながら分析を行う。

## 3. 提案手法

本研究では、Discord ディレクトリサイトと呼ばれるウェブ 사이트からサーバ情報を収集し、その中からサイバー犯罪に関連する可能性が高いサーバを特定して参加したうえで、そのサーバ内に投稿されているメッセージを分析する。提案手法の処理の流れを図 1 に示す。以下では、対象サーバの絞り込みから、参加したサーバ内に投稿されたメッセージの収集、分析までの一連の流れを詳述する。なお、本稿における時刻はすべて協定世界時 (UTC) とする。

### 3.1 Discord サーバ情報の収集

メッセージの収集対象となる Discord サーバを選定するた




図 1: システムフローチャート

め、Discord ディレクトリサイトから Discord サーバ情報 (サーバ名、説明文、招待リンク) を収集する。本研究では、掲載されているサーバ情報数が多い Discord 公式サイト [7], Discord Home [8], DiscordServers.io [9] の 3 件のディレクトリサイトをサーバ情報収集対象とした。

### 3.2 サイバー犯罪関連サーバの絞り込み

Discord サーバへの参加時には CAPTCHA 等の認証が求められる場合があり、その手続きを自動化することは困難であるため手動で行う必要がある。また、1 アカウントあたりのサーバ参加上限数による制約も存在する。このように、すべてのサーバに参加を試みることはコストの観点から現実的ではないため、収集したサーバ情報を事前に絞り込む必要がある。まず、第 3.1 節にて収集したサーバ情報に含まれる招待リンクに対し、Discord API [10] を使用して現在も使用可能であることを検証する。次に、LLM を用いて本研究の参加対象とすべき Discord サーバを選定する。収集したサーバ情報は膨大であり、かつ多言語やスラング、隠語が使用されている場合があるため、この処理は LLM が適している。LLM のモデルとして

は、判定能力に優れたモデルである gpt-oss-safeguard-20b [11] を利用した。LLM への入力は、収集したサーバ情報に含まれる Discord サーバ名と Discord サーバ説明文、およびプロンプトである。出力形式は JSON とし、サイバー犯罪に関連しているか否かの 2 値判定とその理由を得る。

### 3.3 Discord サーバへの参加

招待 URL が有効であり、かつサイバー犯罪に関連すると LLM によって判定されたサーバを対象に、実際に参加を試みる。本プロセスは、CAPTCHA 認証やサーバ内でのロール選択、メッセージへのリアクションなど、自動化が困難な操作を伴う可能性があるため手動で実施する。

### 3.4 参加したサーバからメッセージ収集

メッセージの収集には、Python ライブラリである discord.py-self [12] を使用した。本ライブラリは、Discord アカウントの認証トークンを使用することで、当該アカウントが参加しているサーバの情報やメッセージ履歴を収集可能にするものである。

### 3.5 サイバー犯罪関連メッセージの絞り込み

収集したメッセージ群から、サイバー犯罪に係るメッセージを抽出するために LLM を用いた分析を行う。サイバー犯罪のカテゴリ分類としては、第 2.3 節で述べた Tsakalidis ら [5] の提案したカテゴリ分類を採用した。LLM のモデルとしては、前節と同様に gpt-oss-safeguard-20b [11] を利用した。入力は、収集したメッセージ本文とプロンプトであり、出力はメッセージがどのサイバー犯罪カテゴリに分類されたか（関連がない場合は null）を示す JSON 形式とした。

## 4. 結果と分析

### 4.1 Discord サーバ情報の収集結果

本研究では、サーバ情報の収集元として、Discord 公式サイト [7]、Discord Home [8]、および DiscordServers.io [9] の 3 件のディレクトリサイトを選定した。収集期間は 2025 年 10 月 27 日から 2026 年 2 月 23 日までである。収集したサーバ情報数、およびその中で LLM によりサイバー犯罪に関連があると判定されたサーバ数を表 1 に示す。表中の「総数」はディレクトリサイト上の掲載エントリ数（サーバ名・説明文・招待 URL の組）を指し、「ユニーク数」は Discord API から取得したサーバ ID に基づく実際のサーバ数を指す。同一サーバが異なる招待 URL で複数掲載されている場合、前者では別々に、後者では 1 件として計上される。また、Total 行は各サイトの単純合計、Total(unique) 行は 3 サイトを横断してサーバ ID の重複を排除した値である。3 サイト横断でのユニークなサーバ数は 44,404 件であり、そのうち LLM によってサイバー犯罪に関連性が高いと判定され、本研究の分析対象候補となったサーバは 1,298 件であった。

### 4.2 Discord サーバへの参加結果

LLM によってサイバー犯罪関連と判定されたサーバ情報 1,298 件に対して全件参加を試みた。参加結果およびメッセージ収集の成否を表 2 に示す。参加を試みた Discord サーバ 1,298 件のうち、1,123 件への参加に成功した。その後、参加したサーバからメッセージの収集を試みた結果、1,090 件のサーバ

表 1: Discord サーバ情報の収集結果と LLM による判定結果

| ディレクトリサイト         | 収集したサーバ情報数 |        | サイバー犯罪関連数 |       |
|-------------------|------------|--------|-----------|-------|
|                   | 総数         | ユニーク数  | 総数        | ユニーク数 |
| Discord Official  | 25,167     | 21,853 | 420       | 320   |
| Discord Home      | 4,174      | 4,125  | 120       | 106   |
| DiscordServers.io | 77,781     | 19,801 | 3,194     | 891   |
| Total             | 107,122    | 45,779 | 3,734     | 1,317 |
| Total(unique)     | —          | 44,404 | —         | 1,298 |

からメッセージを取得できた。メッセージの収集は 2026 年 1 月 23 日から 2026 年 2 月 26 日まで行った。

表 2: Discord サーバへの参加およびメッセージ収集の成功数

|                 | サーバ数  |
|-----------------|-------|
| 参加を試みたサーバ数      | 1,298 |
| 参加に成功したサーバ数     | 1,123 |
| メッセージを取得できたサーバ数 | 1,090 |

### 4.3 収集したメッセージの分析結果

サーバへの参加およびメッセージの収集が成功したデータのうち、LLM によってサイバー犯罪に関連すると判定されたメッセージ数を表 3 に示す。収集したメッセージ総数は 795,266 件であり、投稿本文の重複を除外したユニークメッセージ数は 532,988 件となった。これらのメッセージに対し LLM を用いた分析を行った結果、サイバー犯罪に関連すると判定されたメッセージは 19,806 件（全体の 3.7%）であった。

表 3: 収集したメッセージに対するサイバー犯罪関連メッセージ数の割合

| 項目            | ユニークメッセージ数 | 割合     |
|---------------|------------|--------|
| メッセージ総数       | 532,988    | 100.0% |
| サイバー犯罪関連メッセージ | 19,806     | 3.7%   |

収集したデータセットの背景をより詳細に把握するため、メッセージの言語分布を分析した。言語判定には Python ライブラリである langdetect [13] を使用し、テキスト内容に基づき各メッセージの言語を推定した。空文字列や絵文字、記号、URL のみで構成されるような判定が困難なメッセージは「判定不可」として分類した。

収集した全 532,988 件のメッセージのうち、言語判定が可能なテキストを含むメッセージは全体の 97.1% であり、残り 2.9% (15,660 件) が判定不可であった。言語別では英語が 359,396 件 (67.4%) と最も多く、次いでポルトガル語 (3.3%)、スペイン語 (3.0%)、フランス語 (2.0%)、ベトナム語 (2.0%) と続いた。

さらに、サイバー犯罪に関連すると判定された 19,806 件のメッセージについても言語分布を調査した。その結果、判定不

可は 299 件 (1.5%) に留まり、98.5% のメッセージが解析可能であった。解析可能なメッセージの中では英語が最も多く、サイバー犯罪関連メッセージ全体の 72.0% を占めた。続いてスペイン語 (4.0%)、ポルトガル語 (3.8%)、フランス語 (2.8%)、ベトナム語 (2.5%) となり、その他の言語はそれぞれ 1.5% 以下の割合であった。データセット全体では計 43 言語が観測されており、Discord 上でのサイバー犯罪活動が主に英語で行われている一方で、多様な言語コミュニティにまたがって展開されていることが示された。

次に、サイバー犯罪関連メッセージのカテゴリ分類の内訳を表 4 に示す。なお、カテゴリの定義には、第 2.3 節で述べた Tsakalidis らが提案した分類 [5] を使用した。サイバー犯罪に関連すると判定されたメッセージ 19,806 件のうち、カテゴリ A が 8,796 件 (44.4%) と最も多く、次いでカテゴリ D が 6,075 件 (30.7%)、カテゴリ B が 3,891 件 (19.6%)、カテゴリ C が 1,002 件 (5.1%)、カテゴリ E が 42 件 (0.2%) となった。

表 4: サイバー犯罪関連メッセージのカテゴリ内訳

| サイバー犯罪カテゴリ | ユニークメッセージ数 | 割合     |
|------------|------------|--------|
| カテゴリ A     | 8,796      | 44.4%  |
| カテゴリ B     | 3,891      | 19.6%  |
| カテゴリ C     | 1,002      | 5.1%   |
| カテゴリ D     | 6,075      | 30.7%  |
| カテゴリ E     | 42         | 0.2%   |
| Total      | 19,806     | 100.0% |

4.4 収集したメッセージ内に含まれていた招待リンク

Discord サーバ内外のつながりを明らかにするため、収集したメッセージ内に含まれる URL を抽出し、分析を行った。

全ユニークメッセージ 532,988 件、およびそのうちサイバー犯罪に関連すると判定された 19,806 件のメッセージから抽出された、各 URL のユニーク数を表 5 に示す。なお、ここではプラットフォーム特有の URL として、Discord サーバへの招待リンク、ファイル共有サービスである MEGA の URL、および匿名性の高いメッセージングアプリである Telegram の URL の 3 種に着目した。

表 5: メッセージから抽出された URL の分類と件数

| 項目            | 全メッセージ  | サイバー犯罪関連 |
|---------------|---------|----------|
| 対象メッセージ総数     | 532,988 | 19,806   |
| ユニーク URL 総数   | 163,095 | 12,932   |
| Discord 招待リンク | 7,043   | 1,019    |
| MEGA URL      | 746     | 231      |
| Telegram URL  | 825     | 450      |

表 5 より、対象メッセージ数に対する抽出 URL 数の単純な割合を比較すると、全メッセージにおいては約 30.6% (163,095 件) であるのに対し、サイバー犯罪関連メッセージにおいては約 65.3% (12,932 件) と顕著に高くなっている。これは、サイ

バー犯罪に関連する投稿において、外部プラットフォームへの誘導やファイルの共有が頻繁に行われていることを示唆している。また、全メッセージに対するサイバー犯罪メッセージの割合は全体の 3.7% に過ぎないにもかかわらず、全 Telegram URL の過半数 (825 件中 450 件) がサイバー犯罪メッセージから検出されている点も特筆すべきである。

さらに、サイバー犯罪に関連するメッセージから抽出された URL について、第 4 表で示したサイバー犯罪カテゴリごとの内訳を表 6 に示す。

表 6: サイバー犯罪カテゴリ別の抽出 URL 内訳

| カテゴリ          | URL 総数 | Discord | MEGA | Telegram |
|---------------|--------|---------|------|----------|
| カテゴリ A        | 4,958  | 456     | 53   | 92       |
| カテゴリ B        | 1,786  | 157     | 11   | 197      |
| カテゴリ C        | 608    | 153     | 15   | 144      |
| カテゴリ D        | 5,823  | 287     | 154  | 37       |
| カテゴリ E        | 10     | 3       | 0    | 0        |
| Total(unique) | 12,932 | 1,019   | 231  | 450      |

カテゴリ別の傾向を見ると、カテゴリ D (著作権に関する犯罪) において MEGA の URL が 154 件と最も多く観測されており、海賊版ソフトや違法コンテンツの配布にオンラインストレージが多用されていることがうかがえる。一方で、カテゴリ B (コンピュータに関連する犯罪) やカテゴリ C (コンテンツに関連する犯罪) においては、URL 総数に対して Telegram URL の占める割合が比較的高くなっている。これは、詐欺活動や違法性の高いコンテンツの取引において、Discord から Telegram へとユーザを誘導し、より追跡が困難な環境でコミュニケーションを継続しようとする意図が反映されていると考えられる。

4.5 各サイバー犯罪カテゴリに対して発見したメッセージ例

以下では LLM によりサイバー犯罪に関連すると判断されたメッセージをカテゴリごとに調査する。

4.5.1 カテゴリ A: コンピュータデータおよびシステムの機密性、完全性、可用性に対する犯罪

コンピュータデータ及びシステムへの脅威に関する犯罪が属するカテゴリ A では、図 2 に示すように、2TB の攻撃トラフィックを送信可能で最大 5 時間の攻撃を行えるボットネットの販売を宣伝するメッセージが投稿されていた。




図 2: ボットネットの販売宣伝メッセージ

4.5.2 カテゴリ B: コンピュータに関連する犯罪

コンピュータに関する犯罪が属するカテゴリ B では、図 3 に示すように、オンラインストアや実店舗の購入証明書の偽造サービスの宣伝メッセージが投稿されていた。

4.5.3 カテゴリ C: コンテンツに関連する犯罪

コンテンツに関する犯罪が属するカテゴリ C では、表 6 に






図 3: 購入証明書の偽造サービスの宣伝

示した通り、URL 総数に対する Discord 招待 URL の割合が約 25.2% と十分メッセージが収集できた A, B, C, D の 4 カテゴリ中で最も高く、サーバ間の密接なリンク関係が示唆された。そこで、カテゴリ C のメッセージから抽出された Discord 招待 URL を起点にリンク先サーバへ参加し、さらにその投稿内の招待 URL を辿ることで、サーバ間のネットワークを部分的に可視化・分析した。図 4 に得られたネットワークの一例を示す。本ネットワークはディレクトリサイト DiscordServers.io を共通の起点とする 4 つの経路から構成されており、以下の 3 つの共通の特徴が観測された。第 1 に、リダイレクト専用サーバの介在である。4 経路中 3 経路で、コンテンツを持たず招待リンクのみを投稿するリダイレクトサーバが確認され、意図的な多段階の誘導構造の存在が示された。第 2 に、プラットフォームを横断した配布網である。複数の経路で Discord, Telegram, MEGA にまたがるリンク構造が確認された。ボットによる定型文の繰り返し投稿やバックアップサーバの設置など、サーバ削除への耐性を意図した冗長な構成が観測された。第 3 に、カテゴリ C とは無関係なサーバの入口化である。アカウント売買やゲームエクスプロイト等、カテゴリ C 以外の目的を掲げるサーバが経路の起点となり、カテゴリ C のサーバへユーザを誘導する構造が観測された。以上は部分的な事例に基づく分析であるが、多段階の誘導構造や複数プラットフォームを横断した冗長なリンク構造の存在は、単一のサーバやプラットフォームの削除のみでは配布活動の抑止が十分でない可能性を示唆している。




図 4: カテゴリ C の投稿に含まれる招待 URL から繋がるネットワーク例

#### 4.5.4 カテゴリ D: 著作権に関する犯罪

著作権に関する犯罪が属するカテゴリ D では、図 5 に示すように、動画配信サービスや、VPN サービスのアカウントの不正配布の誘導メッセージが投稿されていた。




図 5: アカウントの不正配布誘導メッセージ

#### 4.5.5 カテゴリ E: 複合的な犯罪

複合的な犯罪が属するカテゴリ E では、図 6 に示すように、仮想通貨系オンラインカジノゲームの予測ツール・認証済みアカウント・配当金のロンダリング手法に関するメッセージが投稿されていた。




図 6: 複合的な犯罪に関するメッセージ

## 5. 評価

本節では、提案手法の有効性を検証するため、(1) サーバ識別精度の評価、および (2) メッセージのカテゴリ分類精度の評価の 2 つの観点から検証を行う。さらに、提案手法全体における、事前のサーバ情報に基づく絞り込みプロセスの有効性についても評価する。

### 5.1 サーバ識別精度の評価

サーバ単位でのサイバー犯罪関連の識別精度を評価するため、ローカル LLM によってサイバー犯罪に「関連する」と判定されたサーバ 50 件、「関連しない」と判定されたサーバ 50 件の計 100 件からなる評価データセットを構築した。

各サーバについて、サーバ名および説明文と、直近に投稿された公開メッセージ最大 50 件を収集した。2 名の評価者がこれらの情報を独立して確認し、当該サーバがサイバー犯罪に関連しているか否かの二値ラベルを付与した。

提案手法における事前の識別プロセスはサーバ情報のみを用いて判定を行うが、手動評価で正確な正解データを作成するため、評価者にはサーバ情報に加えて直近のメッセージ群も提示した。これは、サーバ情報のみでは記述が曖昧であったり隠語が使われていたりして、サイバー犯罪との関連性を判断するには情報が不十分なケースが存在するためである。一方で、数千件に及ぶ可能性のある全メッセージ履歴を確認することはコストの観点から現実的ではない。そのため、評価対象を直近 50 件のメッセージに制限することで、サーバの活

動状況を把握するのに十分かつ現実的な情報量とした。

評価者には、違法な取引や目的など、サイバー犯罪に関連する明確な証拠に基づいて判定を下すよう指示した。意見の不一致が生じた場合は議論によって解決し、最終的な正解データを作成した。

構築した正解データとローカル LLM による判定結果を比較し、適合率 (Precision)、再現率 (Recall)、F1 スコアを算出した結果を表 7 に示す。

表 7: サーバ情報の事前識別精度

| カテゴリ           | Precision | Recall | F1-score | Support |
|----------------|-----------|--------|----------|---------|
| Non-cybercrime | 0.88      | 0.90   | 0.89     | 49      |
| Cybercrime     | 0.90      | 0.88   | 0.89     | 51      |
| Macro Avg      | 0.89      | 0.89   | 0.89     | 100     |

提案手法の全体的な正解率 (Accuracy) は 0.89 であり、両クラスにおいてバランスの取れた性能を示した。サイバー犯罪関連サーバに対する適合率は 0.90、再現率は 0.88 であり、関連のないサーバに対する適合率も 0.88、再現率は 0.90 であった。これらの結果は、参加前のサーバ情報を用いた判定において、関連の有無を安定して識別できていることを示している。

なお、独立した初期評価における評価者間の一致度を示す Cohen's  $\kappa$  は 0.46 となった。この値が中程度に留まった要因として、提案手法の LLM と同様に「サーバ情報自体」の記述を重視するか、サンプリングされた「直近 50 件のメッセージ」に含まれる犯罪の痕跡を重視するかで、評価者間で判定の重みが分かれたことが挙げられる。しかし、意見の不一致が生じた際のコンセンサス形成において、「メタデータの説明文等からサイバー犯罪との関連性が十分に判断できる場合は、直近 50 件のメッセージ内に直接的なサイバー犯罪関連の投稿が確認できなくとも『関連する』と判定する」という基準で最終的な合意を図った。提案手法におけるローカル LLM はサーバ情報のみを用いて事前判定を行っているため、このメタデータを重視した最終的な正解データの基準が LLM の判定傾向と強く合致した。結果として、初期の評価者間一致度 ( $\kappa$  係数) が中程度であったにもかかわらず、最終的な正解データに対する LLM の識別精度 (F1 スコア 0.89) は高く算出されるに至った。

## 5.2 提案手法全体の有効性

情報収集のパイプライン全体において、事前のサーバ情報による絞り込みがどの程度有効に機能したかを評価するため、実際に参加に成功したサーバを分析した。参加した 1,090 件のサーバのうち、911 件 (83.6%) において少なくとも 1 件のサイバー犯罪関連メッセージが確認された。これは、サーバ情報のみを用いて識別したサーバの大部分が、実質的なサイバー犯罪関連活動を内包していることを意味する。この結果は、事前の絞り込みプロセスが、分析対象として関連性の高いサーバを効果的に抽出できていることを示している。

## 5.3 メッセージのサイバー犯罪カテゴリ分類精度評価

メッセージ単位の分類精度を評価するため、主要な 4 つの

サイバー犯罪カテゴリ (A~D) およびサイバー犯罪に関連しない (null) カテゴリのそれぞれから 100 件ずつ、計 500 件のメッセージをランダムに抽出した。ここでは発生頻度の極めて低いカテゴリ E は除外した。

各メッセージは、メッセージ本文のみに基づいて 2 名の評価者が独立して確認し、カテゴリ A~D、または null のいずれかを付与した。評価者はローカル LLM に与えたプロンプトと同一の基準に従い、違法な取引や明確な有害意図など、サイバー犯罪に関連する明示的な証拠を要求した。そのような証拠が存在しない、あるいは曖昧な場合、該当メッセージは null と判定した。意見の不一致は議論を通じて解決し、最終的な正解データを決定した。

評価結果を表 8 に示す。全体の正解率 (Accuracy) は 0.84 であった。なお、評価者間の一致度は Cohen's  $\kappa = 0.68$  であり、メッセージ単位での分類基準が明確に定義され、一貫して解釈可能であることが確認された。

表 8: メッセージに対する LLM のカテゴリ分類精度

| カテゴリ        | Precision | Recall | F1-score | Support |
|-------------|-----------|--------|----------|---------|
| null (関連なし) | 0.97      | 0.72   | 0.83     | 135     |
| カテゴリ A      | 0.89      | 0.72   | 0.79     | 124     |
| カテゴリ B      | 0.78      | 0.97   | 0.87     | 80      |
| カテゴリ C      | 0.86      | 0.98   | 0.91     | 88      |
| カテゴリ D      | 0.71      | 0.97   | 0.82     | 73      |
| Macro Avg   | 0.84      | 0.87   | 0.84     | 500     |

表 8 より、モデルは null クラスに対して 0.97 という極めて高い適合率を達成している。これは、本研究が曖昧なケースを非関連とみなす厳格な判定基準を採用したことと整合しており、誤検知 (False Positive) が低く抑えられていることを示している。同時に、サイバー犯罪カテゴリの再現率は最大 0.98 に達しており、モデルが明示的な犯罪関連メッセージを多数捕捉できている一方で、カテゴリの特性によって分類性能に差異が生じていることが確認できる。

## 5.4 アノテーションの一貫性

評価データとローカル LLM の挙動の間で一貫性を担保するため、本研究では LLM のプロンプトと同一の評価基準を用いて手動アノテーションを実施した。しかし、特にサーバ単位のタスクにおいては、サーバ情報とメッセージ内容から得られる複数のシグナルを統合的に解釈する必要があるため、本質的な曖昧さが残存する。

これに対処するため、本研究では曖昧なケースを null と判定する厳格な判定基準を採用した。この設計により無関係なメッセージの過剰検知を防ぎ、実際の LLM の分類ポリシーに沿った正確な評価結果となるよう担保している。

## 5.5 エラー分析

本提案システムの限界を明らかにするため、ローカル LLM の分類結果と人間の評価者による正解データとの間に生じた系統的な差異についてエラー分析を行った。

第一に、カテゴリ A（機密性・完全性・可用性に対する犯罪）とカテゴリ B（コンピュータに関連する犯罪）の間で頻繁な混同が観察された。特に、クレジットカード情報などのデータ販売について、LLM は詐欺行為（カテゴリ B）と解釈する傾向があった。対して評価者は、それらが詐欺スキームの直接的な実行ではなく、システムへの不正アクセス等に関連する手段の提供であるとみなし、カテゴリ A に分類した。

第二に、カテゴリ A とカテゴリ D（著作権に関する犯罪）の間でも混同が生じた。例えば、Netflix などのストリーミングサービスアカウントの販売に対し、LLM は著作権侵害（カテゴリ D）と分類することが多かった。一方で評価者は、コンテンツ自体の違法配布ではなく不正アクセスの手段となるアカウント提供に焦点が当てられていると判断し、カテゴリ A とした。

最後に、文脈が乏しい、または隠語により曖昧なメッセージは頻繁に null と判定された。これは厳格な判定基準を反映した結果であり、誤検知を削減する効果がある一方で、境界線上にある関連メッセージを見逃す可能性を示唆している。

総じて、分類エラーは意味的に類似するカテゴリ間で集中しており、主に LLM による表面的な文脈解釈と、評価者による犯罪の意図的・機能的な解釈の差異に起因している。これらの知見は、より複雑な文脈や隠語のシグナルを取り入れ、犯罪としての機能的な役割を LLM に明示的にモデル化させることで、分類性能をさらに向上させられる可能性を示している。

## 6. まとめと今後の課題

本研究では、Discord 上におけるサイバー犯罪の現状を網羅的に把握し、かつプライバシー保護を両立させるため、事前定義されたキーワードに依存せずローカル LLM を活用した新たな情報収集・分析システムを提案した。本システムを用いて、ディレクトリサイトから収集したサーバ情報をもとに疑わしいサーバを識別・参加し、取得した全メッセージのカテゴリ分類を行った。結果として、1,090 件のサーバから 19,806 件のサイバー犯罪関連メッセージを抽出し、コンピュータデータやシステムに対する犯罪（カテゴリ A）や著作権に関する犯罪（カテゴリ D）が多く行われている実態を明らかにした。

今後の課題として、第一に「システムの分類精度の改善」が挙げられる。本手法のエラー分析により、LLM がメッセージの表面的な文脈解釈に依存し、ストリーミングアカウント等の不正販売をカテゴリ A ではなく、カテゴリ B やカテゴリ D へ誤分類してしまうケースなど、解釈の曖昧さが明らかになった。今後は、今回判明した分類における曖昧な指示をより精緻に調整し、Discord の投稿に最適化したプロンプトを作成することで、分類性能のさらなる向上を目指す。

第二に、「招待 URL からなるネットワークの分析」である。収集したメッセージの分析から、サイバー犯罪に関連する投稿には、Discord サーバへの招待リンクや、Telegram、MEGA といった外部プラットフォームへの URL が頻繁に含まれていることが確認された。今後は、これらのリンクのつながりを起点としてプラットフォーム横断的なネットワーク構造を可視

化・分析し、サイバー犯罪のエコシステム全体をより深く解明していく方針である。

## 7. 研究倫理

本研究におけるデータ収集および分析のプロセスは、ユーザーやプラットフォームへのリスクを最小化し、プライバシーを厳重に保護するための配慮の下で遂行された。

まず、データ収集にあたっては、誰でも参加可能な公開サーバおよびチャンネルのメッセージのみを対象とした。認証の迂回やユーザーとの直接的なやり取り、プライベートメッセージの収集は一切行わず、プラットフォームのアクセス頻度制限を遵守した受動的なデータ収集に留めている。また、データの処理にはローカル環境に展開した LLM を使用し、分析結果はすべて集計値として扱うことで、個人や特定のサーバが識別されないよう匿名性を厳格に担保した。

さらに、本研究で収集したすべてのメッセージに対して、分析対象をテキスト情報のみに厳格に限定している。メッセージに付随する添付ファイル等のコンテンツのダウンロードおよび分析は一切実施していない。くわえて、データ収集は仮名アカウントを用い、管理された環境下で行うことで研究者自身の安全確保にも努めている。

**謝辞** 本研究の一部は N E D O（国立研究開発法人新エネルギー・産業技術総合開発機構）の委託事業「経済安全保障重要技術育成プログラム／先進的サイバー防御機能・分析能力強化」（JPNP24003）によるものである。

### 文 献

- [1] Discord. About Discord. <https://discord.com/company>.
- [2] Leonardo Nizzoli, Serena Tardelli, Marco Avenuti, Stefano Cresci, Maurizio Tesconi, and Emilio Ferrara. "charting the landscape of online cryptocurrency manipulation". *IEEE Access*, Vol. 8, pp. 113230–113245, 2020.
- [3] Daniel G. Heslep and P. S. Berge. "mapping discord's darkside: Distributed hate networks on disboard". *New Media & Society*, Vol. 26, No. 1, pp. 534–555, 2024.
- [4] 川口大翔, Yin Minn Pa Pa, 吉岡克成, 松本勉. "discord 上のサイバー犯罪に対する ChatGPT を利用した情報収集システム". 2024 年 暗号と情報セキュリティシンポジウム (SCIS2024), 2024.
- [5] George Tsakalidis and Kostas Vergidis. "a systematic approach toward description and classification of cybercrime incidents". *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, Vol. 49, No. 4, pp. 710–729, 2019.
- [6] Council of Europe. Convention on cybercrime. European Treaty Series No. 185, 2001. Available at <https://rm.coe.int/1680081561>.
- [7] Discord. Discord Servers - Home. <https://discord.com/servers>.
- [8] Discord Home. Discord Servers. <https://discordhome.com/>.
- [9] DiscordServers.io. Find Discord Servers. <https://disforge.com/>.
- [10] Discord. Discord Developer Portal, Invite Resource. <https://discord.com/developers/docs/resources/invite#get-invite>.
- [11] OpenAI Platform. gpt-oss-20b. <https://openai.com/ja-JP/index/introducing-gpt-oss-safeguard/>.
- [12] dolfies. discord.py-self: A fork of the popular discord.py for user accounts. <https://github.com/dolfies/discord.py-self>.
- [13] Michal Danilák. langdetect. <https://github.com/Mimino666/langdetect>, 2021. Version 1.0.9.